

项目名称（暂定）

基于图神经网络与历史路径行为的自适应最短路加速方法

一、我想做什么

我想研究一种新的图最短路加速方法。

传统最短路算法，如 Dijkstra、A* 以及各类分层预处理方法，主要依据图本身的拓扑结构进行搜索或预处理。它们在一般图上很有效，但往往默认“所有查询都是平均的”“图的结构本身就足够决定怎样加速”。而在真实工程场景中，大量最短路查询并不是均匀随机出现的，而是带有明显的人群行为规律、热点区域和高频通路。现实中的用户并不是平均地在整张图上移动，而是会不断重复经过一些区域、通道和中转节点。已有路线规划研究也普遍依赖预处理和层次结构来换取更快查询。

基于这一观察，我希望提出一种**面向历史查询负载的学习式图抽象方法**：先利用大量历史最短路查询记录，把这些查询中蕴含的流量分布、热点节点、常用路径片段等信息编码到原图中；然后将带有这些历史行为信息的图输入图神经网络，学习出每个节点的任务相关表示；再依据学习到的表示对图进行聚类、分块或粗化，得到一张更适合当前查询负载的新图结构；最后在这些不同规模、不同角色的子图上，分别使用 Floyd、Dijkstra、A* 等经典算法进行针对性的预处理与查询。

简单来说，我不是想让 AI 直接替代最短路算法，而是想让 AI 学会：**面对真实的查询习惯，怎样把图改造成更适合经典算法发挥作用的样子**。现有图学习工作里，已经有很多图 pooling / graph coarsening / structure learning 的方法，但它们大多服务于图分类、表示学习或通用结构压缩，而不是专门面向最短路查询负载。

二、这个研究想解决什么问题

这个研究主要想解决三个问题。

1. 传统图预处理“机械”，不够贴近真实使用场景

现有很多缩点、分层、shortcut、hub 类方法，主要根据拓扑重要性或静态规则构造层次结构。这些方法非常强，但它们对“真实查询分布”通常没有直接建模。也就是说，它们擅长处理“抽象意义上的路网最短路问题”，但未必最适合“某一类人群反复在同一张图上查询路径”的真实系统。

2. 历史查询中蕴含了大量可利用的信息，却没有被充分用来重构图

如果一张图上已经积累了大量历史最短路查询，那么这些数据事实上已经告诉我们：

- 哪些节点是高频中转点
- 哪些边经常被经过
- 哪些区域之间往返频繁
- 哪些路径片段具有重复复用价值

这些信息不应该只作为“统计结果”存在，而应该反过来参与图的预处理结构设计。

3. 经典算法很强，但缺少“面向任务负载的自适应前置结构”

Dijkstra、A*、Floyd 等算法本身并没有问题，问题在于它们通常运行在“未经任务定制的图”上。我的目标是通过学习方法，为这些经典算法构造一个更适合当前工作负载的图划分和预处理框架，从而减少平均查询成本。

三、这个研究的核心创新点在哪里

我目前设想的创新主要在下面三个层面。

创新点 1：引入“历史查询负载”来驱动图抽象，而不是只依赖静态拓扑

传统分层和预处理方法主要根据图结构本身构建层次。我的想法是把历史查询行为作为一等信息源，让图的抽象方式不再只是“机械的结构压缩”，而是“面向真实查询负载的自适应重组织”。

一句话概括就是：

不是只看图长什么样，而是看人们实际上怎样用这张图。

创新点 2：不是让 GNN 直接求最短路，而是让 GNN 学习“怎样重构求解空间”

这点我觉得很重要。

很多“AI+图论”的做法容易落入一个误区：试图让神经网络直接预测最短路径或最短距离。但最短路是一个经典且成熟的问题，完全替代经典算法并不现实，正确性、稳定性和解释性都很难保证。已经有工作尝试用 GNN 近似最短路或缩小搜索子图，但这条路线天然面临和经典精确算法直接对打的问题。

我的做法不是替代，而是结合：

让 GNN 学习如何进行图划分、节点表征、区域抽象和结构重参数化；再让经典最短路算法在这个学习得到的结构上运行。

这是一种“学习 + 经典算法”的混合范式。

创新点 3：提出“学习式图划分 + 异构经典预处理”的整体框架

我不只是想做一个 embedding 再聚类，而是希望形成一个完整框架：

- 用历史查询构造图特征
- 用 GNN 学习节点表示或角色分数
- 基于表示进行聚类/粗化/分区
- 针对不同规模和性质的子图，分配不同的经典预处理策略
- 必要时通过门户节点或回退机制保证全局查询质量

也就是说，创新不只是“用了 GNN”，而是：

将查询历史、学习式图抽象、子图分治和经典算法异构调度统一到一个框架里。

四、预期可以带来什么价值

1. 工程价值

如果方法有效，那么对于拥有大量重复路径查询的系统，例如校园导航、园区交通、物流园路径规划、游戏地图导航、机器人固定区域移动等场景，它可以显著降低平均查询时间，提高系统吞吐量，并使预处理结构更贴近真实使用模式。路线规划文献已经表明，预处理换查询速度是这一领域的核心思路之一。

2. 学术价值

这个方向连接了三个原本相对分开的领域：

- 图最短路与路线规划
- 图神经网络与图粗化/图池化
- 面向真实查询负载的系统优化

因此它不是单纯“套一个 AI 壳子”，而是一个有交叉研究价值的题目。

3. 展示价值

这个项目非常适合做可视化和 demo。

例如可以直观展示：

- 原图与学习后抽象图的差异
- 热点查询如何影响图分块
- 不同方法下的搜索范围变化
- 平均查询时间和展开节点数对比

这对找团队、申请项目、做比赛展示、说服导师都很有帮助。

五、研究的基本技术路线

我目前设想的技术路线如下：

第一步：构造历史查询驱动的图特征

从大量历史最短路查询中提取统计信息，构造节点和边特征，例如：

- 节点被经过次数
- 边被经过次数
- 节点作为中转点的频率
- 不同时间段的热度分布
- 常见 OD 对之间的路径共现关系

第二步：利用 GNN 学习节点表示

将原图连同上述历史特征输入图神经网络，学习每个节点的嵌入向量、重要性分数或角色标签。

第三步：基于学习结果进行聚类/分区/粗化

按照节点表示对图进行分块，形成若干子图或高层区域结构，并识别跨子图的门户节点。

第四步：对子图采用异构预处理策略

依据子图规模和结构特征，选择适合的经典方法进行预处理，例如：

- 小规模稠密子图：Floyd
- 中等规模子图：Dijkstra 或多源最短路
- 稀疏跨区连接：A*、双向搜索或门户索引

第五步：在线查询与动态更新

在线查询时，优先在学习得到的区域结构上进行粗粒度决策，再进入相关子图做细化搜索。随着历史查询分布变化，可以局部更新特征、重新聚类或微调模型，使系统具备一定动态适应能力。

六、这个研究目前最大的难点

这个方向虽然有潜力，但也有明确挑战。

1. 训练目标怎么设计

GNN 学出来的表示必须真正服务于最短路预处理与查询效率，而不是只产生“看起来合理”的聚类结果。也就是说，需要定义清楚优化目标：究竟是最小化平均查询时间、展开节点数，还是最小化预处理与查询的综合成本。现有图粗化工作非常多，但任务目标往往不是 shortest-path workload。

2. 怎样兼顾效率与正确性

如果只是简单地分块后拼接路径，可能损害全局最优性。因此必须设计合理的跨块连接、门户节点机制，以及必要时回退到原图精确搜索的保底策略。

3. 如何避免对历史热点过拟合

如果模型过度依赖热门查询模式，可能导致冷门查询性能下降。因此需要研究它在“平均性能”和“最坏情况”之间的平衡。

七、目前阶段的目标

我希望先完成一个初步原型，验证这个想法是否可行。短期目标包括：

1. 选定一张真实或半真实图数据集
2. 构造历史查询样本
3. 完成“历史特征 + GNN 表征 + 图聚类”的第一版实现

4. 与 Dijkstra、A* 以及简单人工分块方法做实验对比

5. 评估平均查询时间、展开节点数、路径质量和更新开销

如果原型结果有亮点，再继续推进完整论文和系统化实验。