

08: Oracle 到底是什么

1. 最直接的答案

在本项目中，Oracle 是：

先查看每个候选区域的真实收益标签，再直接按真实收益从高到低排序的理想选择器。

它已经知道答案，所以不是现实部署时可用的方法。它的用途是提供一个上界，并测量其他排序方法还有多少改进空间。

2. “Oracle”这个词的一般含义

Oracle 原意接近“神谕”或“能给出正确答案的先知”。在算法和机器学习论文里，它通常指一个拥有现实算法拿不到的信息、能作出理想决策的参照物。

不同项目里的 Oracle 定义可能完全不同。阅读论文时不能只看名字，必须问：

1. 它提前知道了什么？
2. 它在哪个候选空间里最优？
3. 它优化哪个指标？
4. 它是否受相同预算和约束？

3. 它不是 Oracle 数据库

这里的 Oracle 与 Oracle Corporation、Oracle Database、SQL 或数据库服务没有关系。

它也不是一个叫 Oracle 的神经网络，不需要训练，不会预测未来。

4. 本项目 Oracle 的严格算法

设 1,200 个候选区域的真实平均收益分别为：

```
gain[0], gain[1], ..., gain[1199]
```

分析取前 10%，所以 $K = 120$ 。Oracle 做的事情只有：

按 gain 从大到小排序

若收益相同，按 region_id 从小到大打破平局

取前 120 个

计算这 120 个区域的平均真实收益

源码中 Oracle 实际调用 `_top_mean(gains, gains, k)`：第一个 gains 用来排序，第二个 gains 用来评估。排序分数和答案是同一个量，所以它必然得到理想排序。

实现位于 `scripts/analyze_region_labels.py`。

5. 一个小例子

假设只有五个候选，真实收益是：

区 域	真实收 益
A	8
B	20
C	5
D	14
E	2

预算只能选两个。Oracle 看完答案后选 B 和 D，平均收益是：

$$(20 + 14) / 2 = 17$$

一个 Proxy 可能给出排序 A、B、D、C、E，于是选 A 和 B，真实平均收益是：

$$(8 + 20) / 2 = 14$$

Oracle 与 Proxy 的差是 3。它表示：在这五个固定候选、同一标签和“选两个”的规则下，Proxy 排序仍留下 3 的平均收益空间。

6. 为什么 Oracle 的 Spearman 和 NDCG 都是 1

Spearman 是什么

Spearman 相关系数比较两组数的**排名顺序**是否一致：

- 1：排序完全一致；
- 0：没有稳定的单调排序关系；
- -1：排序完全相反。

Oracle 用真实收益给真实收益排序，所以 Spearman 必然是 1。

NDCG@K 是什么

NDCG 是排序质量指标。它不只看选中了哪些高收益项目，还让排名越靠前的位置权重越大。

@K 表示只关心前 K 个。理想真实收益排序的 NDCG 定义为 1，因此 Oracle 的 NDCG@120 也是 1。

这两个 1 不是实验发现，而是 Oracle 定义导致的结果。

7. Oracle 与真实标签不是两个不同算法

Oracle 没有额外产生一套标签。真实收益标签先由精确查询得到；Oracle 只是用这些标签直接

排序。

可以这样区分：

- **标签**：每个区域的答案数值；
- **Oracle**：读取答案并按答案排序的选择规则；
- **Proxy**：不读取标签，用手工历史特征评分；
- **模型**：用训练数据学习从允许输入到收益预测的映射。

8. Oracle 为什么不能部署

部署时要选择服务未来查询的区域，但未来查询还没发生，所以没有未来真实收益标签。

如果为了得到收益先把所有 1,200 个候选分别对未来查询跑一遍精确实验，那么选择问题本身已经被离线穷举解决，而且使用了未来信息。它既昂贵又违反预测场景。

模型的任务正是用过去可见信息逼近这个未知的真实收益排序。

9. Oracle 是“全世界最优”吗

不是。当前 Oracle 只在以下受限条件内最优：

- 候选池固定为这 1,200 个区域；
- 每个候选固定 512 个节点；
- 标签是单区域平均展开收益；
- 标签查询固定为某一批样本；
- 选择规则是按单区域收益取 Top-120；
- 没有在 Oracle 排序中处理最终区域重叠和精确字节预算。

它不能发现候选池之外的新区域，也不保证 Top-120 能作为一个不重叠集合同时物化，更不是整个道路图上任意区域集合的全局最优解。

因此更准确的名称是“固定候选、固定标签口径下的排序 Oracle”。

10. 同样本 Oracle 为什么可能过于乐观

如果在查询样本 A 上计算标签，再选 A 上收益最高的区域，并仍在 A 上报告收益，Oracle 会利用 A 中的抽样噪声。

某个区域可能只是碰巧特别适合 A 中多抽到的几条查询，却未必对另一批查询同样好。

所以项目额外做**跨样本 Oracle 选择**：

1. 用第一批标签选出第一批 Oracle Top-K；
2. 不改变所选区域，在第二批独立查询上看它们的收益；
3. 再反过来用第二批选、第一批评；
4. 与同一个 Proxy 选择结果比较。

11. 为什么旧筛查数字不再沿用

项目曾在“热点 + 空间均匀 + 随机”的旧候选池上做两批独立查询筛查。该候选池后来因需求偏置被正式替换，产物已归档。因此旧筛查只能说明标签程序当时具有重复性，不能证明当前全图固定随机池的 Oracle 差距或抽样稳定性。

当前主线只报告新候选池上固定 2,000 查询的正式结果。结构冻结后还要用更大查询批次或新时间窗口复核，不能借用旧池数字填补证据。

12. 当前正式 2,000 查询标签上的 Oracle

当前正式 1,200 × 2,000 CSV 重新分析得到：

排序方法	Spearman	NDCG@12	Top-120 平均真实收益
	n	0	益
原始端点频率	0.8661	0.9366	126.037

排序方法	Spearman	NDCG@12	Top-120 平均真实收益
	n	0	益
第一版 midpoint Proxy	0.9017	0.9730	133.161
Oracle	1.0000	1.0000	134.908

因此：

Oracle - 第一版 Proxy = 134.908 - 133.161 = 1.747

Oracle - 原始频率 = 134.908 - 126.037 = 8.871

当前第一版 Proxy 在整体排序和 Top-120 收益上都很强，Oracle 剩余空间只有 1.747。这仍是正差距，但意味着 NBFNet 必须直接超过强 Proxy，不能只以优于随机排序作为成功标准。

13. Oracle 差距为什么是阶段门

如果 Oracle 与简单 Proxy 几乎没有差距，可能意味着：

- 候选池中最好区域已经被简单规则完全识别；
- 标签噪声过大；
- 候选之间真实差异太小；
- 标签定义不能反映想优化的东西。

此时增加复杂 GNN 很难产生有意义的部署提升。应该先检查候选和标签，而不是堆模型。

当前跨样本差距为正，说明候选和标签中仍存在 Proxy 没有捕获的信息，值得继续尝试学习。

14. 训练期 Oracle 与测试期 Oracle

实施计划中的“训练期真实收益 Oracle”只作为上界。严格实验还要区分：

- 训练标签 Oracle：在训练标签上知道答案；
- 验证标签 Oracle：在验证窗口知道答案，只能用于理解上界；
- 最终测试 Oracle：在最终测试完成后计算，用于说明候选空间上限，绝不能用于选模型。

任何 Oracle 都不能和可部署模型放在同一口径下宣称“可实际达到”。图表应明确标注上界。

15. Oracle 不等于基线

项目里容易混淆的几个参照：

- **原图基线**：不压缩，直接运行双向 Dijkstra；
- **随机/热点基线**：第一版和传统实验中的区域选择策略，不是当前候选生成口径；
- **Proxy-only**：第一版手工代理评分；
- **MLP 基线**：学习真实标签，但不做图消息传递；
- **Oracle 上界**：直接读取真实标签排序。

Oracle 是排序上界；原图基线是查询工作量参照。它们回答不同问题。

16. 当前分析状态怎样区分

分析脚本把不同规模的证据明确分成四类：候选子集试跑、全候选筛查样本、正式抽样标签和完整 Y 窗口。当前 `1,200 × 2,000` 结果属于 `formal_sampled_labels`，阶段状态是 `ready_for_modeling`；它不是 `pilot`，也不冒充完整约 34,329 条查询的 Y 窗口。

因此，`label_manifest.json` 的 `status=complete` 和正式分析的 `ready_for_modeling` 含义一致：固定的正式抽样标签任务已经完整完成，可以进入模型阶段；完整 Y 窗口只作为后续复核。

下一章解释未来模型怎样尝试逼近 Oracle，而又不读取 Oracle 才知道的未来标签。