

09：第二版确定采用的双向 NBFNet

1. 先说明当前事实

本章同时描述冻结设计、基础五种子结果、已完成的核心消融和当前纯传播证伪实验。

截至 2026-07-31，统一数据接口、CUDA 无传播 MLP、基础 NBFNet 五种子和核心消融已完成。

基础实现采用严格需求边界注入、零保持有向传播、全 128 原型精确混合梯度、混合精度和

激活重计算。正式结果的 holdout Spearman 为 0.8873 ± 0.0039 ，与 MLP 基本持平；

NDCG@K 为 0.9821 ± 0.0025 ，Top-K 平均真实收益为 129.051 ± 0.000 ，均超过 MLP

与原始频率。但随机重连、无向图和去边特征重新训练后几乎恢复相同结果，因此不能说

“传播已证明有效”。当前改用空间隔离切分和切断直通的 32 层纯传播做最后验证。

2. 先理解 NBFNet 在本项目中的含义

Neural Bellman-Ford Network (NBFNet) 可以理解成“让 Bellman-Ford 式的多跳候选传播变得可学习”。它不是把经典最短路算法改成近似神经网络，也不会替代在线 Dijkstra。本项目只借用它的三个思想：从指定需求源注入状态、沿有向边逐轮传播、让不同道路和传播深度的影响由真实区域收益来决定。

原始 NBFNet 通常一次处理一个查询条件。Porto 图和历史 OD 数量都很大，第二版不会逐条 OD 在全图上重复计算，而是把历史 OD 压缩成少量“需求原型”，对原型分批传播，再按原型出现频率汇总区域价值。若去掉这些条件而只保留两个节点频率场，它就只是普通 GNN，不能作为第二版主模型。

3. 模型要接收什么输入

对每个道路节点，第一轮核心输入计划包含：

- 历史窗口中作为起点的归一化次数；

- 历史窗口中作为终点的归一化次数；
- 入度；
- 出度；
- 相邻边长度；
- 道路类型。

此外，模型还接收由历史 OD 形成的需求原型条件。原型至少保留起点集合、终点集合和出现权重；原型构造只使用历史 OD 和静态道路图，不使用历史最短路径。

入度与出度

- 入度：有多少条有向边指向该节点；
- 出度：有多少条有向边从该节点出发。

它们描述道路连接角色，例如一个节点可能是多条路汇入的点，或多个可驶出方向。

坐标不是第一轮默认核心特征，只计划作为单独消融。这样能检查模型是否只是记住固定城市位置，而没有学习可迁移的道路结构。

4. 什么是节点表示

模型不能直接对“节点编号 12345”做有意义计算。它会把每个节点的原始特征转换成一个数值向量，例如：

```
[0.12, -0.38, 0.91, ...]
```

这个向量叫作表示、嵌入或 hidden state。每一维不一定有人类预先指定的含义，而是训练中为了预测区域收益逐渐形成。

5. 两套初始需求场

对每个需求原型，每个节点建立两套独立状态：

- O^0 : Origin 初始场, 强调该原型的起点需求;
- D^0 : Destination 初始场, 强调该原型的终点需求。

起点编码器 f_0 和终点编码器 f_D 不共享参数, 因为“从这里出发的需求”与“要到这里结束的需求”在有向路网上语义不同。

公式:

$O_v^0 = f_0(\text{节点静态特征, 节点 } v \text{ 的起点计数})$

$D_v^0 = f_D(\text{节点静态特征, 节点 } v \text{ 的终点计数})$

上标 (0) 表示传播前的第 0 层。

6. 为什么起点场正向传播

历史中经常从节点 u 出发的需求, 可能沿 u 的出边影响下游道路。起点场因此按原图方向:

$u \rightarrow v$

传播到 v 。

节点 v 从所有指向自己的入边发送者接收起点消息。

7. 为什么终点场反向传播

如果许多需求最终到达节点 t , 那么能够沿有向道路通往 t 的上游区域可能有价值。

要从终点向“可能到达它的来源方向”传播, 就要沿反图前进。等价地, 节点 v 从它在原图中的出边邻居接收终点方向消息。

起点和终点方向分开, 正是第二版相对第一版固定无向扩散的关键区别。

8. 什么是消息

在一层图传播中，相邻节点不会原样复制所有状态，而是经过一个可学习变换 Φ 产生消息。

消息可以同时读取：

- 发送节点状态；
- 接收节点状态；
- 边长；
- 道路类型；
- 方向。

这样模型可以学到“不同道路类型和距离上的需求影响应该怎样衰减或变形”。

9. 什么是注意力

一个节点可能有多个邻居，但不同邻居并不一定同样重要。注意力机制为每条消息计算权重 α ，再做加权求和。

起点场的一层可概念化为：

候选新起点状态
= 所有入边邻居消息 $\times$ 各自注意力权重 的总和

注意力权重由训练学习，不是预先规定“短边一定更重要”。

10. 什么是门控

如果每一层都完全替换节点状态，多层传播可能把原始本地需求冲淡。门控 g 决定保留多少新消息、多少旧状态：

新状态 = $g \times$ 聚合消息 + $(1 - g) \times$ 旧状态

g 接近 1 时更相信邻居传播；接近 0 时更多保留本地信息。它可以是每个节点、每层、每个向量维度不同的可学习值。

11. 为什么两套传播参数不能共享

如果起点和终点传播完全共享参数，模型被迫假设：

需求从起点向外扩散的规律，与从终点沿反图追溯的规律相同。

道路方向、出入口结构和 OD 分布未必满足这个对称假设。第二版完整模型因此使用两套参数，而“共享参数”会作为消融对照。

12. 什么是传播深度

一层消息传递让节点看到一跳邻居，两层可以间接看到两跳邻居。层数越深，理论感受范围越大，但也可能：

- 计算更贵；
- 把局部差异过度平滑；
- 引入无关远处需求；
- 训练更不稳定。

第一版手工选择固定扩散步数。第二版计划同时保留第 0 到第 L 层状态，并学习融合权重。

13. 可学习深度融合

模型为不同层学习 $\beta_0, \beta_1, \dots, \beta_L$ ，经过 softmax 归一化后加权组合。

Softmax 把任意实数变成总和为 1 的非负权重。例如原始打分经过 softmax 后可能得到：

```
第 0 层: 0.10
第 1 层: 0.45
第 2 层: 0.30
```

这表示模型更依赖一跳和两跳信息，但仍保留本地与更远信息。权重也可作为解释结果报告。

后续改进一：倍增传播

普通逐层传播通常每增加一层只多看到一跳道路邻居。道路路径可能包含很多节点，直接堆叠大量层会很慢。基础 NBFNet 验证成立后，第二版将尝试按 1、2、4、8... 的尺度传播，让较少层数覆盖更远道路范围。

倍增连接只能从静态道路图本身构造，例如重复邻接或先把相邻道路聚合成粗粒度节点。它不允许读取历史最短路径，也不能根据标签窗口或最终测试窗口决定跳到哪里。

后续改进二：跨层注意力残差

深层传播可能逐渐冲淡最初的本地需求。跨层注意力残差让模型有选择地读取已经传播过的较浅层和较深层状态，再通过残差通道保留信息。严格纯传播实验禁止最终读出直接读取第 0 层，避免再次形成原始输入逃逸路径。

这项设计借鉴深层注意力网络中的跨层信息保留思想。正式实验分别比较：纯深层传播、只加残差、只加倍增尺度读出、残差与倍增同时加入。

14. 起终点场怎样组合

每一层计划组合四类信息：

1. 起点状态 O ;
2. 终点状态 D ;
3. 逐元素乘积 $O \odot D$;
4. 逐元素绝对差 $|O - D|$ 。

逐元素乘积

两个同长度向量在相同位置相乘。它用来表达起点影响和终点影响同时较强的潜在交汇。

绝对差

它描述两个方向需求的不平衡。例如一个区域可能大量向外出发，却很少作为终点方向的上游。

这些只是可学习表示，不是声称模型恢复了真实最短路径走廊。

15. 从节点表示到区域表示：池化

一个候选包含 512 个节点，但需要输出一个区域分数。把一组节点向量汇总为一个区域向量叫作池化。

基础实现先固定使用排列不敏感的 mean 和 max pooling：

- mean pooling：512 个节点表示取平均；
- max pooling：每一维取所有节点中的最大值；
- attention pooling：作为基础传播成立后的读出层消融，学习哪些节点对区域价值更重要。
- 入口边界：需求从区域外进入区域的潜在强度；
- 出口边界：需求从区域离开的潜在强度；
- 内部交汇：起点场和终点场在区域内部的兼容程度。

入口、出口和内部交汇读出仍是核心消融的一部分，但不混入第一次基础模型训练。这样可以先确认双向传播本身是否有效，再判断更复杂读出层是否提供额外贡献。

池化应对节点排列顺序不敏感，因为同一个节点集合换个列表顺序仍是同一区域。

16. 需求分支与成本分支

计划结构：

```
demand_branch = 双向 NBFNet 区域池化
cost_branch   = 边界数 + 内部节点数 + shortcut 数
prediction    = 两个分支融合后的预测头
```

预测头是把区域向量转换成一个标量预测收益 $\hat{y}_R$ 的小型神经网络。

核心传播分支禁止读取局部接入工作量、查询耗时、回退率等容易复制答案的统计。

17. 损失函数是什么

损失函数把“预测有多错”压缩成一个数。训练器计算损失对参数的梯度，再调整参数使损失减小。

基础实现的总损失由 Huber 和 Pairwise ranking 两部分组成，权重与无传播 MLP 对齐。未来需求辅助损失保留为后续消融，不进入第一次正式训练。

Huber 损失

它用于学习具体收益数值。误差小时像平方误差，误差很大时增长更温和，减少极端候选对训练的支配。

Pairwise ranking 损失

它抽取两个候选，要求真实收益更高的候选预测分数也更高。项目最终更关心选出 Top-K，所以只拟合数值还不够，排序损失能直接强调相对顺序。

未来需求辅助损失

可以让节点表示小权重预测后续起终点需求，帮助表示学习。但它只能是辅助任务，不能替代真实区域收益主损失，否则又回到“优化需求 Proxy，而非查询收益”。

18. 什么是反向传播

一次训练步骤可简化为：

输入历史特征

↓ 前向计算

预测区域收益

↓ 与真实标签比较

得到损失

↓ 反向计算每个参数对损失的影响

更新预测头、池化、深度权重、门控、注意力和编码器

“端到端”表示损失梯度能够一直传回最早的起点场与终点场，而不是只训练最后一个预测头。

19. 为什么先完成无传播 MLP

MLP 是多层感知机。这里它可以读取区域中节点的原始历史频率和静态特征，但不在图边上传递邻居消息。

先做 MLP 有三层意义：

1. 验证真实标签是否能被历史输入学到；
2. 建立不使用图传播的强学习基线；
3. 检查数据、训练和区域池化链路，再增加复杂传播模块。

如果 MLP 都无法稳定学习标签，直接训练更复杂 GNN 很难定位问题。

当前这一步已经完成。统一接口把历史需求和静态道路特征池化为 64 维区域输入，使用 64、32 两个隐藏层训练五个随机种子。Candidate holdout 上：

- Spearman: 0.8914 ± 0.0238 ，原始频率为 0.7957 ；
- NDCG@K: 0.9556 ± 0.0153 ，原始频率为 0.9661 ；
- Top-K 平均真实收益: 126.000 ± 1.853 ，原始频率为 128.530 。

这五次正式训练均由 PyTorch CUDA 在 NVIDIA GeForce RTX 3050 Laptop GPU 上完成。

五个种子全部通过可学习性阶段门，状态为 `ready_for_nbfnet`。这里的 holdout 是同一 H→Y 时间对内留出的候选，不是最终未来时间测试；它证明数据与无传播学习链路成立，但不证明

跨时间泛化。

20. 必做对比

第二版计划至少比较：

1. 固定候选上的随机排序；
2. 原始起终点频率排序；
3. Risk-only；
4. 第一版 Proxy-only；
5. 原始起终点频率 + 区域 MLP；
6. 第一版固定无向扩散 + MLP；
7. 普通共享参数 GraphSAGE；
8. 第二版 OD 条件化双向 NBFNet；
9. 训练期真实收益 Oracle 上界。

21. 必做消融

包括：

- 删除全部传播；
- 换成固定均值扩散；
- 只保留起点场；
- 只保留终点场；
- 两场共享参数；
- 忽略道路方向；
- 删除边长与道路类型；
- 删除交汇项；

- 只用最后一层，不学习深度融合；
- 删除排序损失。
- 打乱起点—终点配对，只保留边际频率；
- 用普通 GraphSAGE 替换 NBFNet 式逐轮传播；
- 删除需求原型条件，只保留全局起点和终点场；
- 在基础 mean/max 读出之外加入 attention pooling，并单独比较入口—出口边界读出。
- 删除倍增传播，恢复普通逐层邻接传播；
- 删除跨层注意力残差，只保留相邻层更新；
- 分别比较基础、倍增、跨层残差和组合模型，并匹配参数量与训练预算。

22. 什么结果才算 NBFNet 传播成立

最低证据要求是：

- OD 条件化双向 NBFNet 稳定优于原始频率、固定扩散、GraphSAGE 和无传播 MLP；
- 删除起点场或终点场都会稳定变差；
- 有向传播优于无向传播；
- 保留 OD 配对关系优于打乱配对的边际频率模型；
- 边界感知读出优于普通区域池化；
- 提升不只出现在训练损失，还出现在未来窗口的真实工作量和在线配对耗时；
- 多个随机种子结论一致；
- 所有距离正确率仍为 100%。

如果完整模型只优于随机，却没有优于 MLP 和 cost-only，就不能说双向需求传播贡献成立。