

11：术语表

本章按主题列出前文出现的名词。定义以本项目语境为准。

A. 道路图与查询

图 (graph)

由节点和边构成的数学结构，不是图片。

节点 (node / vertex)

道路图中的离散位置，例如路口或道路形状点。

边 (edge)

两个道路节点之间允许行驶的直接连接。

有向图 (directed graph)

边有方向的图。 $A \rightarrow B$ 存在不代表 $B \rightarrow A$ 存在。

带权图 (weighted graph)

每条边有成本。本项目当前用道路长度作为权重。

邻接表 (adjacency list)

为每个节点保存它能直接走到哪些节点的结构。

反向邻接表 (reverse adjacency)

为每个节点保存哪些节点能直接走到它，用于反向搜索和终点场传播。

入度 (in-degree)

指向一个节点的边数。

出度 (out-degree)

从一个节点发出的边数。

OD

Origin-Destination，一条起点到终点的出行需求记录。

吸附 (map matching / snapping, 此处是最近节点吸附)

把轨迹经纬度映射到附近道路节点。当前项目不是完整轨迹地图匹配，只处理首尾点。

查询 (query)

给定起点和终点，请算法返回最短距离的一次请求。

可达 (reachable)

有至少一条合法有向路线能从起点到终点。

最短路 (shortest path)

总边权最小的可行路线。

最短距离 (shortest distance)

最短路所有边权之和。项目在线主要返回这个值。

B. 最短路算法与指标

Neural Bellman-Ford Network (NBFNet)

一种把 Bellman-Ford 式多跳状态传播做成可学习网络的架构。原始 NBFNet 常用于查询条件化的链路预测；本项目把它改造成区域价值预测器：历史 OD 原型分别从起点正向、终点反向传播，再汇总到固定候选区域。它只参与选区，不负责在线最短路，也不提供精确性保证。

OD 条件化传播

传播状态不只由节点自身频率决定，还带有起点—终点需求原型的条件。这样模型可以区分“从哪里出发、通常去哪里”的不同需求，而不是把所有起点和终点混成两个独立热点图。

需求原型

由历史 OD 聚合得到的一小组代表性需求模式。原型用于降低逐条 OD 全图传播的计算量，同时保留起点和终点的配对关系。原型不是历史最短路径，也不包含路径监督。

双向 NBFNet

本项目的第二版主模型名称。起点分支沿原图方向传播，终点分支沿反图传播；两者在节点和区域层面交汇，再与独立成本分支共同预测真实压缩收益。

Dijkstra

适用于非负边权图的精确最短路算法。

双向 Dijkstra

同时从起点正向和终点反向搜索的 Dijkstra 变体。

松弛 (relaxation)

检查经过当前节点是否能得到更短邻居距离的操作。

展开节点 (expanded / settled node)

算法已确认当前最短距离并正式处理的节点。项目用展开数衡量确定性查询工作量。

正确率 (correctness rate)

压缩查询距离与原图参考距离一致的查询比例。

容差 (tolerance)

比较浮点距离时允许的极小数值差，当前默认 `1e-6`。

P50

中位数，50% 查询不超过这个耗时。

P95

95 分位数，约 95% 查询不超过这个耗时，用来观察较慢查询尾部。

配对评测 (paired evaluation)

让同一条 OD 的基线与压缩查询在同一进程紧邻执行，并交替先后顺序，减少环境漂移。

非配对耗时 (unpaired timing)

两个方法不是以逐查询紧邻方式测量的耗时，不适合直接声明微小性能差。

C. 区域压缩索引

索引 (index)

用额外预计算与存储减少后续查询工作的结构。

区域 (region)

一组连通道路节点。当前第二版候选固定为 512 个节点。

连通 (connected)

忽略方向后，区域节点之间不存在完全孤立的部分。

BFS

Breadth-First Search，广度优先搜索；从种子按图跳数向外逐层生长区域。

种子节点 (seed node)

BFS 区域生长的起点。

边界节点 (boundary node)

区域内至少有入边或出边连接区域外的节点。

内部节点 (internal node)

属于区域、但不是边界的节点；压缩图中会被删除。

外部节点 (outside node)

不属于被压缩区域的节点。

Shortcut

用一条等价有向边保存区域内两个边界之间的精确最短距离。

物化 (materialization)

真正构建并存储压缩图，而不是查询时临时计算抽象结构。

压缩图 (compressed graph)

删除区域内部节点、保留边界和外部节点、加入 shortcut 后的图。

索引预算 (index budget)

允许索引使用的资源上限，例如 shortcut 条数或存储字节数。

端点局部接入 (endpoint local access)

内部起终点只在所属区域中搜索到边界，再连接压缩图的精确查询办法。

前沿 (frontier)

搜索的初始节点及其已有距离。局部接入可产生多个边界前沿。

LRU 缓存

容量满时淘汰最久未使用条目的缓存策略。

回退 (fallback)

压缩查询无法处理某情况时改用完整原图。第二版内部端点已不再触发整图回退。

D. 数据、实验与监督

特征 (feature)

模型可以读取的输入数值，例如历史起点频率或节点入度。

标签 (label / target)

监督学习希望模型预测的答案。第二版主标签是单区域平均展开节点收益。

监督学习 (supervised learning)

使用输入和已知标签训练模型的学习方式。

无路径监督 (path-free supervision)

不使用历史最短路径节点、边或经过次数作为模型输入或标签。

查询反馈监督 (query-feedback supervision)

运行精确查询后只保存工作量差、耗时汇总等反馈，不保存路径序列。

历史窗口 H

较早时间段的 OD，用于构造模型输入。

标签窗口 Y

紧随 H 的后续 OD，用于测量区域真实收益。

时间隔离 (temporal separation)

确保 H 与 Y 不重叠，验证与最终测试继续位于更晚时间。

数据泄漏 (data leakage)

训练或选配置时使用现实预测时拿不到的未来答案或测试信息。

随机种子 (random seed)

初始化伪随机生成器的整数。相同代码、输入和种子应产生相同抽样或打乱结果。

Pilot

小规模试运行，用来检查链路、稳定性和成本，不是最终完整结论。

阶段门 (stage gate)

进入下一研究阶段前必须满足的条件。

消融实验 (ablation)

删除或替换组件，判断该组件是否有独立贡献的控制变量实验。

基线 (baseline)

用于比较的参考方法。不同问题有不同基线，例如原图查询基线和区域选择基线。

E. 排序与统计

Proxy

容易计算、希望与真正目标相关的代理指标。第一版 midpoint Proxy 不是实际压缩收益。

Oracle

查看真实收益标签后按答案排序的理想选择器，只作为固定候选空间中的上界。

Top-K

按分数排序后取最前面的 K 个候选。

Spearman

比较两组排名单调一致性的相关系数，范围通常是 -1 到 1。

NDCG@K

强调高收益候选和前排位置的 Top-K 排序质量指标，理想排序为 1。

MAE

Mean Absolute Error，平均绝对误差。

标准差 (standard deviation)

描述数值围绕均值分散程度的统计量。

边际收益 (marginal gain)

加入一个区域相对不加入它造成的收益变化。当前标签测的是单区域独立收益。

集合归因 (set attribution)

多个区域共同部署时，如何把整体收益归因给每个区域的问题。

上界 (upper bound)

在规定候选、目标和约束下理想方法可达到的参考水平，不一定可部署。

F. 神经网络与 GNN

神经网络 (neural network)

由可学习参数和多层数值变换组成的函数。

参数 (parameter)

训练过程中由优化算法调整的数值，例如线性层权重。

MLP

Multi-Layer Perceptron，多层感知机；本项目中作为不做图消息传递的学习基线。

GNN

Graph Neural Network，允许节点沿图边聚合邻居信息的神经网络。

GraphSAGE

一种聚合邻居表示来更新节点表示的 GNN 架构。第一版使用过。

消息传递（message passing）

节点沿图边发送、聚合信息并更新状态的过程。

表示 / 嵌入（representation / embedding）

模型为节点或区域学习的数值向量。

隐状态（hidden state）

神经网络中间层表示，通常不直接对应人工命名特征。

需求场（demand field）

历史起点或终点需求经编码并沿道路传播后，在所有节点上形成的一组状态。

正向传播场

起点需求沿原有向道路方向传播形成的状态。

反向传播场

终点需求沿反图向可能到达终点的上游传播形成的状态。

注意力（attention）

为不同邻居消息学习不同权重的机制。

门控 (gating)

学习在新聚合消息和旧本地状态之间保留多少的机制。

传播深度 (propagation depth)

消息传递层数，决定节点能间接接触多远的邻居信息。

Softmax

把一组实数转换为非负且总和为 1 的权重。

池化 (pooling)

把一组节点表示汇总为一个区域表示。

预测头 (prediction head)

把学习到的区域表示转换成最终预测收益的网络部分。

损失函数 (loss function)

衡量预测与标签差异、指导参数更新的标量函数。

Huber 损失

结合平方误差的小误差敏感性和绝对误差的大误差稳健性的回归损失。

Pairwise ranking 损失

要求真实收益更高的候选预测排名也更高的成对排序损失。

梯度 (gradient)

参数轻微变化会怎样改变损失的数值信息。

反向传播 (backpropagation)

从损失向前面各层计算梯度并更新参数的训练机制。

端到端 (end-to-end)

最终损失能够更新从输入编码、图传播、池化到预测头的整条可学习链路。

训练、验证、测试

- 训练：更新模型参数；
- 验证：选择结构和超参数，不更新最终结论；
- 测试：所有选择冻结后只用于最终评估。

零样本 (zero-shot)

模型不使用新窗口标签更新参数，直接在新时间窗口上预测和评估。

微调 (fine-tuning)

在已有模型参数基础上，用新数据继续少量训练。

持续学习 (continual learning)

数据随时间到来时分批更新模型，同时避免遗忘和反馈偏置。属于本项目计划中的第三版。