

面向精确最短路查询的图学习区域物化

摘要

道路网络需要重复执行精确最短路查询，但为全图建立索引的成本很高。本文研究如何仅根据历史起终点需求和静态路网，在固定预算下选出少量互不重叠的区域进行预处理。我们先用无参数双向图传播估计区域价值，再用图神经网络修正排序，并同时考虑收益、索引成本和区域冲突。模型只负责离线选区，在线查询仍由精确算法完成。Porto 和 Chicago 实验表明，神经模型在两城多种子和两个时间窗口中均改善全局排序；预算感知版本在 Porto 稳定减少查询工作量，在 Chicago 与无参数方法的差距不超过 3%。全部查询距离正确率为 100%，C++ 测试显示高工作量查询获益更明显。结果表明，该方法能够在有限预算下改善索引资源分配，但全局排序提升不等于实际查询加速，二者需要分别验证。

关键词：Shortest paths; Road networks; Workload-aware indexing; Graph learning; Learning to rank; Region materialization

1 引言

最短路查询支撑交通仿真、出行分析和位置服务。精确图搜索能够直接使用最新路网，但在大量重复查询下会持续消耗计算资源；全量索引可以减少在线搜索，却需要更高的预处理、存储和维护成本 (Dijkstra, 1959; Efentakis et al., 2014)。真实需求又并非均匀分布，因此工程上更关键的不是“是否建立索引”，而是有限资源应优先投向哪些道路区域。

本文围绕一个核心问题展开：**给定历史查询负载和有限索引预算，如何对全部候选道路区域排序，并选择 K 个互不重叠的区域，使其离线物化最大程度提高未来精确查询效率？**区域物化本身——即把区域内部的精确距离汇总为边界连接，使查询可以跳过区域内部——是已有索引技术；以离线计算换取在线速度的思想同样不是本文首创。本文研究的开放问题是**选择**：仅凭历史起终点 (origin-destination, OD) 端点和静态道路图，系统能否学会哪些少量区域最值得投入，同时保证每个在线答案仍然精确？这一问题把需求预测、索引资源配置和精确查询连接起来，也要求模型面对未见区域、未来

负载和真实部署约束，而不能只在离线标签上得到较高相关性。

已有负载感知索引和查询缓存表明，历史负载能够指导最短路加速 (Wan et al., 2022; Dan et al., 2025; Thomsen et al., 2012; Li et al., 2020b)。然而，不同方法管理的是节点标签、完整路径或全图分区，尚不能直接回答少量区域应如何在成本与未来收益之间排序。本文采用成熟的精确区域覆盖结构作为系统底座，把研究重点收敛到历史需求驱动的区域价值估计、预算内集合选择以及无泄漏的端到端验证。

为回答核心问题，本文构造三个递进层次。首先，无参数双向多尺度需求扩散 Z0 (零参数场，名称由此而来) 建立无标签区域排序。随后，深层图网络 BRIDGE (Bidirectional Residual Index Deployment Gain Estimator, 双向残差索引部署收益估计器) 在冻结先验上学习排序残差。最后，预算感知变体 BRIDGE-B 将预算截断处的收益、索引成本和候选冲突联合纳入优化。人工智能始终只负责离线资源配置，不预测最短路距离，也不进入用户请求关键路径；在线查询继续由精确图算法完成。这一设计使确定性先验、神经增量和部署约束能够分别审计，也允许系统在不替换现有查询服务的情况下周期性更新物化区域。

两城实验给出三层答案。首先，神经残差在两城、三种子和两个外部窗口的 12 次配对中一致改善完整候选排序，证明其获得了确定性传播之外的可重复信息。其次，预算感知训练能够稳定保护头部并降低索引成本，Porto 获得跨种子一致的在线工作量改善，Chicago 与强先验的差异保持在 3% 内。最后，全部查询距离正确率为 100%，同实现 C++ 评测和查询尺度分析揭示了高工作量查询更能摊薄区域接入成本，也证明全局排序、预算头部与真实部署收益需要分别验证。

本文的贡献可概括为：

1. 定义需求驱动的选择性区域物化任务，以精确查询工作量减少量衡量区域价值，并给出不进入在线关键路径的旁路标签获取与周期性部署流程。
2. 提出从无参数需求传播、神经排序残差到预算感知联合优化的分层方法，使强确定性先验、可学习增量和部署约束能够分别验证。
3. 建立时间隔离、空间重叠组隔离、严格非重叠选择和精确在线配对组成的验证闭环，在两城多种子实

验中给出从离线排序到真实系统性能的完整证据。

4. 实证区分完整候选排序、预算头部、索引成本和集合级查询收益，并说明高质量全局排序对动态预算、冲突淘汰和全图候补资源配置的工程价值。

本文其余部分安排如下：第二节回顾精确索引、负载感知加速和本文采用的图学习组件；第三节统一符号并形式化问题；第四节给出三个递进方法；第五节说明数据、泄漏控制、基线和评价指标；第六节按照从排序质量到部署与适用性的顺序报告实验；第七节讨论工程含义与局限，第八节总结全文。

2 相关工作

2.1 精确最短路索引与区域覆盖图

精确最短路加速主要通过搜索剪枝、标签索引和分区覆盖图减少在线工作量。可定制路径规划 (Customizable Route Planning, CRP) 把区域内部路径汇总到精确边界连接，并能在压缩图上保持精确距离 (Delling et al., 2017)；SALT 框架将这一分隔式覆盖结构与多类最短路查询统一起来 (Efentakis et al., 2014)。这类研究重点解决索引如何构造以及如何精确查询，通常默认分区方案和物化范围已经给定。本文直接采用这一成熟结构作为底座，进一步研究有限预算只允许物化少量区域时，如何依据未来使用价值决定资源投向。因此，底层覆盖图保证“查得准”，本文的排序与选择负责“物化谁”。

2.2 负载感知索引与最短路缓存

负载感知索引利用查询分布的空间偏斜和时间局部性，把更多索引资源分配给常用对象。WCF 根据历史查询负载调整精确标签索引 (Wan et al., 2022)，FAHL 则把道路流量信息纳入标签构造 (Dan et al., 2025)。它们说明需求信息能够改善精确查询，但管理对象主要是节点标签或索引核心。本文面对的是区域覆盖图中的物化选择：每个候选同时具有收益、边界连接成本和与其他候选的冲突，因此不能直接由节点频率代替。

最短路缓存从另一角度利用历史查询。路径缓存选择可能再次出现的完整路径，区域化缓存还会考虑频率、计算成本与空间覆盖 (Thomsen et al., 2012; Li et al., 2020b)。缓存适合复用已经计算的对象，而本文希望在不读取历史最短路径的条件下，为尚未到来的查询配置精确区域索引。两者共享“依据工作负载分配有限资源”的思想，但输入信息、物化对象和在线复用方式不同。本文因此把历史路径明确排除在模型输入之外，并以未来查询的精确工作量作为最终检验。

2.3 交通图学习与多尺度传播

交通图学习常把道路方向和邻域传播用于流量或速度预测。DCRNN 使用有向随机游走表达道路上的双向空间依赖 (Li et al., 2018)，SIGN 与 Jumping Knowledge 表明多尺度表示有助于结合不同传播范围 (Frasca et al., 2020; Xu et al., 2018)。这些工作主要预测交通状态，而不是为精确查询索引分配区域预算。本文借用成熟的图传播思想，把历史起点与终点需求映射为区域价值，并通过无参数先验与监督残差的分层设计区分固定传播和可学习信息。

2.4 深层图网络与排序优化

深层图网络需要稳定的信息与梯度通路，NBFNet 提供了基于消息传播的图推理组织方式 (Zhu et al., 2021)，残差与跨层读出则是缓解深层训练困难的通用工具 (Li et al., 2020a; Touvron et al., 2021)。学习排序研究进一步提供了可微的顺序近似，使训练目标能够直接关注候选相对次序 (Jagerman et al., 2022)。现有组件为本文提供方法基础，但区域物化还要求同时处理完整排序、预算截断、索引成本和空间冲突。本文的重点是把些目标组织为面向精确道路查询的可部署流程，并用冻结协议检验神经增量是否真正转化为工程收益。

3 预备知识与问题陈述

本节形式化引言提出的核心问题：只依据历史 OD 端点与静态道路图，对全部候选区域排序，并在固定区域数量预算和被审计的索引成本下选择 K 个互不重叠的区域，使其物化最大程度降低未来精确查询工作量。下面依次统一符号、定义候选与精确收益标签，并陈述选择目标。

3.1 道路图、查询负载与时间窗口

给定带正权有向道路图 $G = (V, E, w)$ ，其中 $w : E \rightarrow \mathbb{R}_{>0}$ 表示道路长度。一个查询 $q = (o_q, d_q, t_q)$ 包含起点节点、终点节点和时间戳。将全部查询按 t_q 排序，并以 $\tau_q \in [0, 1)$ 表示查询在该序列中的归一化秩位置，定义三个连续、互不重叠的查询集合：

$$\begin{aligned} H &= \{q : \tau_q \in [0, 0.35)\}, \\ Y &= \{q : \tau_q \in [0.35, 0.70)\}, \\ F &= \{q : \tau_q \in [0.70, 1.00)\}. \end{aligned} \quad (1)$$

分别称 H 为历史集、 Y 为当前标签集、 F 为冻结未来集。 H 只用于构造下文定义的需求输入 (端点边际、节点特征和需求原型)； Y 提供训练标签和 train/validation

模型选择；只有在模型结构、超参数和选择协议全部冻结后才打开 F ，进行零样本时间评测。

历史窗口仅保留起终点边际需求。对节点 v ，定义

$$\begin{aligned} h_O(v) &= \frac{1}{|H|} \sum_{q \in H} \mathbf{1}[o_q = v], \\ h_D(v) &= \frac{1}{|H|} \sum_{q \in H} \mathbf{1}[d_q = v]. \end{aligned} \quad (2)$$

方法不读取 H 中任一查询的最短路径。

全文所称**区域物化**，是指把候选区域内部的精确距离预先编码为边界连接，并在查询图中用这些连接替代区域内部节点；**区域收益**是物化后每条查询减少的搜索工作量；**完整排序**是对所有候选给出的连续优先级，而非一个固定预算下的单一集合；**预算头部**是区域数量或索引成本截断点附近的候选；**严格非重叠部署**要求任意两个同时物化的区域不共享道路节点。

3.2 候选区域与精确收益标签

候选集合 $\mathcal{R} = \{R_1, \dots, R_M\}$ 在全图节点上以固定随机种子尽量空间均匀地产生，每个候选是包含 512 个节点的连通子图。候选生成不读取历史 OD、标签或模型输出。区域 R 的边界集合 B_R 包含与区域外节点相邻的节点，其余节点构成内部集合 I_R 。

区域价值以搜索工作量衡量，具体记为搜索终止前 Dijkstra 类算法已确定的**展开节点数**。对查询 q ，记原图双向 Dijkstra 的展开节点数为 $N_G(q)$ ，只物化区域 R 后的覆盖图搜索与端点局部接入总展开节点数为 $N_R(q)$ 。区域的监督标签定义为

$$y_R^Y = \frac{1}{|Q_Y|} \sum_{q \in Q_Y} [N_G(q) - N_R(q)], \quad (3)$$

其中 $Q_Y \subset Y$ 是从当前标签集 Y 中以预先固定随机种子抽取的 2,000 条查询，本文称之为**标签查询**。未来标签 y_R^F 使用完全相同定义，但仅在最终评测时从 F 生成。标签衡量精确算法工作量而非不稳定的单次 Python 墙钟时间；每条查询同时校验索引距离与原图距离相等。

生产侧标签获取与轻量部署。 式(3)属于单区域 overlay 下的反事实工作量，通常不能直接从已有最短路径日志恢复，但无需专门合成新的 OD 负载。在生产系统中，可将少量自然到达的 OD 查询异步镜像到 shadow worker，由 worker 分批轮换或并行分片加载候选区域 overlay，并对同一查询配对记录 $N_G(q)$ 、 $N_R(q)$ 、扫描边、耗时、距离一致性和索引版本。样本达到阈值后即可聚合为区域标签。正式服务仍由当前稳定索引返回精确答案，shadow 执行和神经模型均不进入用户请求关

键路径；训练结束后，生产侧只需周期性接收候选排序与物化计划。因此，工程接入主要增加旁路采样、离线统计和周期性索引维护，不需要把在线最短路径算法替换为神经推理。该协议没有额外 OD 生成成本，并可通过限速、错峰、暂停和并行化控制后台开销；但候选查询计算、overlay 与审计日志存储并非严格为零。本文两城、两窗口、每城 1,200 个候选且每候选 2,000 条查询的 960 万次候选-查询评估，可视为这一 shadow 协议在固定查询集合上的受控、可重复离线模拟。

3.3 选择性物化目标

排序器输出候选分数 s_R 。部署阶段按分数从高到低贪心选择 $K \in \{5, 10, 18\}$ 个区域，且要求任意两个已选区域节点集合严格不相交：

$$|S| = K, \quad R_i \cap R_j = \emptyset, \quad \forall R_i \neq R_j \in S. \quad (4)$$

这一 hard-disjoint 约束来自当前索引的物化语义。式(3)是单区域边际收益，多区域收益不能简单相加，因此最终价值必须通过将整个 S 一次性物化后的真实在线查询确定。

问题可紧凑表述为：只根据 H 和 G 学习候选分数 s_R ，使按 s_R 选出的严格非重叠 $Top-K$ 集合，在受控索引成本下最大化未来精确查询工作量的实际减少量。后续方法均围绕这一评分器构造，实验则逐项检验完整排序、预算头部和真实部署收益。

4 方法

4.1 索引底座：选择性区域物化

对每个被选择区域 R ，离线阶段从每个 $u \in B_R$ 出发，在诱导子图 $G[R]$ 上运行受限 Dijkstra，并对每个可达的 $v \in B_R$ 建立有向 shortcut：

$$w_R(u, v) = d_{G[R]}(u, v). \quad (5)$$

随后删除 I_R ，保留外部节点、边界节点、剩余原始边和 shortcut。该结构沿用已有 CRP/边界覆盖图思想 (Delling et al., 2017; Efentakis et al., 2014)。若查询端点位于某个 I_R ，算法只在该区域内部计算端点至边界的精确距离，并将这些距离作为双向搜索的初始 frontier；若起终点位于同一区域，还比较区域内部直达距离。由此避免整条查询回退原图，同时保持精确性。

距离精确性。 任意穿越区域 R 的原图路径都可按进入和离开 R 的边界节点切分。将其中每段区域内子路径替换为对应 shortcut，不会增加路径长度，因为

shortcut 保存的是 $G[R]$ 内的最短距离；反过来，每条 shortcut 都对应 $G[R]$ 中一条真实路径，因而覆盖图不可能产生比原图更短的非负距离。内部端点通过区域内精确 frontier 接入，起终点同区时另行比较区内直达路径。因此在已选区域互不重叠、shortcut 精确且边权非负的条件下，覆盖图查询与原图最短路径距离相等。实现仍逐查询进行数值校验，不以理论论证替代工程正确性测试。

预处理与查询成本。 设区域 R 的边界数为 b_R 、内部诱导边数为 m_R 。直接从每个边界节点运行一次受限 Dijkstra，预处理复杂度约为 $O(b_R(m_R + |R|) \log |R|)$ ，潜在 shortcut 数为 $O(b_R^2)$ 。因此相同的 512 节点预算并不意味着相同的索引成本：边界更稠密的区域会产生更多 shortcut 和在线扫边。本文同时报告区域节点预算、shortcut 数、展开节点与扫描边，正是为了避免把节点数相同误认为系统成本相同。

4.2 无参数双向多尺度需求场 Z0

首先对历史边际需求进行对数缩放：

$$\mathbf{o}^{(0)} = \log(1 + 1000\mathbf{h}_O), \quad \mathbf{d}^{(0)} = \log(1 + 1000\mathbf{h}_D). \quad (6)$$

令 $P_{\rightarrow}$ 表示沿原图方向、按接收节点归一化的均值传播矩阵， $P_{\leftarrow}$ 表示在反图上的对应传播矩阵。每一层采用带自环的固定 lazy mean：

$$\begin{aligned} \mathbf{o}^{(k+1)} &= \frac{1}{2}(I + P_{\rightarrow})\mathbf{o}^{(k)}, \\ \mathbf{d}^{(k+1)} &= \frac{1}{2}(I + P_{\leftarrow})\mathbf{d}^{(k)}. \end{aligned} \quad (7)$$

在深度集合 $\mathcal{D} = \{1, 2, 4, 8, 16, 32\}$ 上，区域分数为

$$z_R = \frac{1}{|\mathcal{D}|} \sum_{k \in \mathcal{D}} \left[\text{mean}_{v \in R} e_v^{(k)} + \max_{v \in R} e_v^{(k)} \right], \quad (8)$$

$$\mathbf{e}^{(k)} = \mathbf{o}^{(k)} + \mathbf{d}^{(k)}.$$

Z0 不含可学习参数，不读取 Y 或 F 。其目标不是预测路径，而是估计候选区域在多尺度道路邻域中暴露于历史起终点需求的程度。

Z0 的扩散权重、深度和池化均预先固定，因此无法适应标签实际奖励的城市特定结构。空间 holdout 实验同时验证了这一设计的一面：固定需求场已经形成强排序轴，但仍存在只有监督信息才能捕捉的可测残差。下一层方法正是针对这一残差。

4.3 以 Z0 为先验的神经排序残差 BRIDGE

BRIDGE—双向残差索引部署收益估计器—冻结 Z0，只学习其上的加性修正。模型包含起点塔和终点

塔，二者分别沿正图和反图传播且参数不共享，并在多个深度读出。下面依次定义输入、单层传播和区域读出；隐藏宽度固定为 $d = 32$ ，完整模型共有 418,183 个参数。

需求原型与输入注入。 历史集合被压缩为 128 个只由 H 和静态道路图构造的需求原型。原型 p 保存带权起点节点集、带权终点节点集和出现权重 $w_p > 0$ ；以 $a_p(v)$ 、 $b_p(v)$ 表示节点 v 上的起点和终点质量，其他节点取零。每个节点另有静态特征向量 $\mathbf{x}_v$ ，包含入/出度、邻接边长度、道路类型计数和来自 H 的对数缩放端点计数。两个独立双层编码器 E_o, E_d 将 $\mathbf{x}_v$ 映射为 d 维种子，方向 token 用于区分双塔。原型 p 的初始状态为

$$\begin{aligned} \mathbf{h}_{o,p}^{(0)}(v) &= \log(1 + 1000a_p(v))(E_o(\mathbf{x}_v) + \mathbf{t}_o), \\ \mathbf{h}_{d,p}^{(0)}(v) &= \log(1 + 1000b_p(v))(E_d(\mathbf{x}_v) + \mathbf{t}_d). \end{aligned} \quad (9)$$

原型未触及的节点以零向量开始；网络输入是每节点 d 维状态，标量需求只负责缩放编码种子。预测头不读取手工区域特征或第 0 层状态，因此所有学习信息都必须经过图传播。

单层传播。 每层使用边特征门控的 message-aggregate 分支 $\mathcal{F}_\ell$ ，并采用严格恒等的 pre-norm 小残差更新：

$$\mathbf{h}^{(\ell+1)} = \mathbf{h}^{(\ell)} + 0.01 \mathcal{F}_\ell(\text{LayerNorm}(\mathbf{h}^{(\ell)}), E). \quad (10)$$

令 $\mathbf{x} = \text{LayerNorm}(\mathbf{h}^{(\ell)})$ ，每条有向边 (u, v) 的特征 $\mathbf{e}_{uv}$ 拼接道路长度和道路类型 one-hot 编码。分支对每条边计算门控消息，在接收节点处取入边均值，再投影得到输出：

$$\begin{aligned} \mathbf{m}_{uv} &= (W_\ell \mathbf{x}_u) \odot \sigma(U_\ell \mathbf{e}_{uv}) \cdot \sigma(g_\ell([\mathbf{x}_u; \mathbf{x}_v; \mathbf{e}_{uv}])), \\ \mathcal{F}_\ell(\mathbf{x}, E)(v) &= \Phi_\ell \left(\frac{1}{\max\{\deg^-(v), 1\}} \sum_{(u,v) \in E} \mathbf{m}_{uv} \right). \end{aligned} \quad (11)$$

其中 W_ℓ 为线性映射， $\sigma(U_\ell \mathbf{e}_{uv})$ 为逐元素边门， g_ℓ 为输出单一标量门的双层网络， $\deg^-(v)$ 为接收节点入度， Φ_ℓ 为双层投影。终点塔在反图上使用相同形式，但参数独立。该结构用于抑制旧 32 层主干中的反向指数放大；它是已有深层残差思想在本任务中的稳定化实现，不是新的通用残差结构。

多深度读出与区域分数。 双塔在深度集合 $\mathcal{D} = \{1, 2, 4, 8, 16, 32\}$ 读出，以 $\beta_k = \text{softmax}(\boldsymbol{\theta}_\beta)_k$ 学习深度权重。在深度 k ，组合表示为

$$\mathbf{c}_p^{(k)}(v) = [\mathbf{o}_p^{(k)}(v); \mathbf{d}_p^{(k)}(v); \mathbf{o}_p^{(k)}(v) \odot \mathbf{d}_p^{(k)}(v); |\mathbf{o}_p^{(k)}(v) - \mathbf{d}_p^{(k)}(v)|] \in \mathbb{R}^4 \quad (12)$$

以 $\mathbf{u}_p(v) = \sum_{k \in \mathcal{D}} \beta_k \mathbf{c}_p^{(k)}(v)$ 融合深度。区域池化拼接节点均值和最大值，三层感知机 ψ 输出标量，各需求原型再按出现权重组合：

$$\begin{aligned} \mathbf{z}_p(R) &= [\text{mean}_{v \in R} \mathbf{u}_p(v); \max_{v \in R} \mathbf{u}_p(v)] \in \mathbb{R}^{8d}, \\ r_\theta(R) &= \sum_p w_p \psi(\mathbf{z}_p(R)). \end{aligned} \quad (13)$$

ψ 的最终线性层零初始化，因此训练前 $r_\theta \equiv 0$ 。最终分数为

$$s_R = z_R + \alpha r_\theta(R), \quad \alpha \in \{0, 0.125, 0.25, 0.5, 1\}. \quad (14)$$

$\alpha = 0$ 严格回退到 Z0；训练第 0 轮对所有 α 均与 Z0 相同。每个 epoch 的 α 仅在 validation 上选择，同分时优先更小残差。

与评价一致的软 Spearman 目标。 旧 pairwise soft-plus 目标可通过放大分数尺度持续下降，却不保证真实 Spearman 同向变化。为减少这种目标错位，先将批内分数标准化为 $\hat{s}_i$ ，再用成对 sigmoid 构造软排名 (Jagerman et al., 2022)：

$$\tilde{r}_i = \sum_j \sigma\left(\frac{\hat{s}_i - \hat{s}_j}{\tau}\right), \quad \tau = 0.1. \quad (15)$$

设真实标签的平均秩为 r_i^* ，训练损失为

$$\mathcal{L}_{\text{rank}} = 1 - \text{Pearson}(\tilde{\mathbf{r}}, \mathbf{r}^*). \quad (16)$$

精确秩向量上的 Pearson 相关等于 Spearman 秩相关；这里预测秩经过软化，因此式 (16) 是评价 Spearman 的可微替代目标，而不是精确 Spearman 系数。本文称之为软 Spearman 损失。所有模型以 validation Spearman 选择 checkpoint。holdout 和 F 不参与结构、学习率、epoch、 α 或策略选择。

软 Spearman 约束完整候选次序，但不直接描述固定截断点选中哪些候选、shortcut 成本以及候选能否共同部署。下一层方法正是针对这一缺口。

4.4 预算感知增强 BRIDGE-B

BRIDGE 的 soft Spearman 约束完整候选序列，却不直接描述固定预算下的候选截断、索引成本和区域冲突。为此，BRIDGE-B 保留相同的 32 层稳定双塔与冻结 Z0 先验，将残差门固定为 1，并在训练 split 内构造可微 Top- K 权重。对标准化分数 $\hat{s}_i$ ，记停止梯度的第 K 大阈值为 t_K ，定义

$$p_i^{\text{raw}} = \sigma\left(\frac{\hat{s}_i - t_K}{T}\right), \quad p_i = \frac{K p_i^{\text{raw}}}{\text{sg}(\sum_j p_j^{\text{raw}})}, \quad T = 0.15, \quad (17)$$

使软选择质量总和近似为 K 。令 $\bar{y}_{\text{top}} = \sum_i p_i y_i / \sum_i p_i$ ， C_i 为候选 shortcut 数， M_{ij} 表示候选 i, j 是否冲突，训练目标为

$$\mathcal{L}_B = \mathcal{L}_{\text{rank}} - \lambda_g \bar{y}_{\text{top}} + \lambda_b \phi\left(\frac{\sum_i p_i C_i}{B} - 1\right) + \lambda_c \frac{\sum_{i,j} p_i M_{ij} p_j}{(\sum_i p_i)(\sum_i p_i - 1)}, \quad (18)$$

其中 sg 表示停止梯度， $\phi(x) = 0.05 \text{softplus}(x/0.05)$ ；训练预算 B 取同 split 的 Z0 软 Top- K shortcut 成本，快照筛选另使用其 hard-disjoint 成本。 $\lambda_g = 1.0$ 、 $\lambda_b = 1.0$ 、 $\lambda_c = 0.10$ 。全候选最终部署为 18/1200，相同比例对应 train 的 13/840 和 validation 的 3/180。

每个 epoch 都保存 validation 快照。最终 checkpoint 只从更新后的快照中选择：其 hard-disjoint validation Top- K shortcut 不高于 Z0 预算、Spearman 不低于 Z0 减 0.005，并在可行快照中最大化真实 Top- K 平均标签收益。holdout 不参与选择；全候选 Y/F 在线评测只在 checkpoint 冻结后执行。该协议把“排序分数训练”和“集合能否部署”连接起来，同时保留精确在线查询作为不可替代的最终门。

5 实验设计

5.1 数据集与图规模

Porto 使用公开出租车轨迹数据 (Moreira-Matias et al., 2013)，将有效轨迹首末点映射为 OD；Chicago 使用 Divvy 2022 年 6 月共享单车行程 (Divvy, 2022)。Chicago 数据先按字段合法性、时间顺序、研究边界和路网吸附质量清洗，再按完整时间序列等间隔抽取 100,000 条，不依据模型或区域收益筛选。道路网络来自 OpenStreetMap (OpenStreetMap contributors, 2026)；Chicago 固定使用与行程时间接近的 2022 年 1 月 Illinois 历史快照，而不是按实验结果改用最新路网。每城生成 1,200 个 512 节点候选，并划分为 840/180/180 个 train/validation/holdout 候选。对候选两两计算 Jaccard 重叠，当重叠不低于 0.50 时连边，再将整个连通组分配到同一 split。Porto 与 Chicago 分别形成 521 和 452 个重叠组，跨 split 不存在 Jaccard 不低于 0.50 的候选对。

每个城市的 Y 与 F 都对全部 1,200 个候选、各 2,000 条固定查询生成标签，因此两城共包含 960 万次候选-查询标签评估。候选、查询抽样种子和 split 在读取 holdout/future 结果前冻结。

5.2 泄漏控制与冻结顺序

候选区域是空间对象，相邻 BFS 区域常共享大量节点。早期随机 candidate split 中，直接用训练集

Leakage-free temporal protocol




图 1: 本文端到端方法。底层覆盖图采用已有精确索引结构, 本文研究重点是历史起终点需求驱动的区域排序、隔离与选择性物化; 学习只负责离线资源配置, 在线查询始终保持精确。

表 1: 两城数据与冻结切分。

城市	交通数据	节点数	有向边数	全部 OD	H	Y	F
Porto	出租车	133,839	221,589	98,082	34,328	34,329	29,425
Chicago	共享单车	108,114	200,155	100,000	35,000	35,000	30,000

最近重叠区域的标签预测测试候选, Spearman 可达约 0.9936, 表明普通随机划分会严重高估泛化。本文因此先建立阈值 0.50 的 Jaccard 重叠图, 再以连通组为最小分配单元。该规则比只删除完全重复区域更严格, 也避免模型通过共享大部分节点“记住”测试区域。

时间上, H 、 Y 和 F 的查询 ID 与时间范围均无交叉。候选身份在读取 H 前由静态道路图确定; 模型输入只来自 H ; 训练与 validation 标签来自 Y ; holdout 只用于空间外部评测; F 在结构、超参数、种子集合和模型选择策略全部冻结后才解锁。Chicago 只复用 Porto 已确定的协议, 不依据其 holdout、future 或在线结果重新调整深度、学习率、温度与残差门。

上述冻结顺序适用于本文的 Z0/BRIDGE 主验证。BRIDGE-B 是在主实验已经解锁 Y/F 后开展的透明方法扩展: S0-S2 使用 seed 42 开发预算目标, S3 冻结 S2 协议后补 seeds 43/44, 期间不因 seed 43 结果修改 seed 44。因而 S3 支持“同一城市与窗口上的重复种子稳定性”, 不把已解锁的 Y/F 追溯包装为全新时代确认集; 跨时间最终确认仍需新的未来窗口。

5.3 对照方法

本文比较以下方法: 随机排序; 按历史端点频率选择的热点方法; 只使用区域几何中心位置的 midpoint

Proxy; 无区域传播的 MLP; 无参数 Z0; 神经残差 BRIDGE; 以及预算感知增强 BRIDGE-B。MLP 报告 5 个随机种子, BRIDGE 与 BRIDGE-B 报告 42/43/44 三个种子。所有方法共享相同候选池和部署预算, 不允许根据 holdout 或 future 删除不利种子。

其中随机与历史热点回答“是否仅靠任意区域或端点频率即可获益”; midpoint Proxy 检验简单空间位置是否已经足够; MLP 检验在不传播道路邻接时监督区域特征能够达到的水平; Z0 检验固定图扩散; BRIDGE 则只检验监督残差能否超过强先验。Oracle 只用于描述标签空间上界, 不作为可部署方法, 也不参与任何超参数选择。BRIDGE-B 只回答在 BRIDGE 已确认的全局排序轴上, 显式预算目标能否进一步改善固定 $K = 18$ 的头部与在线部署。

5.4 指标与实现

离线排序报告 Spearman、NDCG@ K 和 Top- K 平均真实收益, $K \in \{5, 10, 18\}$ 。部署阶段报告 shortcut 数、平均展开节点变化、平均耗时、P95 耗时和距离正确率。在线变化率均相对同实现原图双向 Dijkstra 计算。BRIDGE 含 418,183 个参数, 采用 CUDA FP32、学习率 5×10^{-3} 、40 个 epoch、无 scheduler。BRIDGE-B 使用相同结构与学习率, 固定 12 epoch、无 scheduler,

以短训门避免在真实部署目标尚未通过时盲目扩大训练。训练只在 GPU 上进行。

C++ 评测在同一 C++20/O3 可执行程序内实现原图与压缩图双向 Dijkstra，固定单 CPU 核，预热 2 轮并正式重复 10 轮。该设计避免把不同语言或不同机器的计时差异误当作算法收益。

神经模型训练在 RTX 4090 D 上使用 CUDA；CPU 只承担数据审计、单元测试和最终 C++ 查询评测。均值与标准差按预先固定的全部种子报告。本文不把不同种子数的方法比较包装为显著性检验，也不在观察 holdout 后删除异常种子。在线计时采用逐查询原图-压缩图配对，查询顺序和实现保持一致；算法无关的系统扰动通过完整干净复跑而不是选择性删除样本处理。

人工智能辅助的软件开发与核验。 研究期间使用 OpenAI Codex 辅助部分 Python/C++ 代码、测试和实验脚本的编写、重构与调试；服务端模型由平台管理，使用时未提供可长期固定的公开版本号。相关改动由作者在本地版本控制下审核，并通过单元测试、固定配置复现、原图-索引逐查询距离一致性检查和机器可读结果审计进行验证。该工具不生成或修改实验观测，不替代正式模型训练，也不承担方法选择、结果解释或最终科学判断。

6 实验结果

本节把核心问题拆成一条验证链：历史需求能否预测区域价值；冻结排序能否跨时间；信号来自哪些机制；排名能否转化为严格非重叠部署；工作量能否转化为墙钟收益；预算头部能否直接训练；收益最终落在哪些查询尺度。七个环节共享同一候选池、预算和精确性约束，不能由单一指标互相替代。

6.1 空间留出候选上的排序质量

Z0 在两城的全局 Spearman 上均高于 midpoint Proxy 与 MLP，说明道路拓扑上的历史需求传播可以形成强区域价值轴。BRIDGE 相对 Z0 的 Porto 三种子增量为 +0.012373/+0.010313/+0.008212，Chicago 为 +0.006405/+0.006515/+0.004035，六次比较方向一致。这一跨城市、跨种子的完全一致性表明，BRIDGE 学到的不是偶然扰动，而是 Z0 之外可重复的全局排序信息。Chicago 的 NDCG@18 呈现不同方向，则形成一组关键对照：soft Spearman 确实优化了完整候选序列，而固定预算下的头部质量由另一目标决定。两类指标的分离不是全局增益失效，而是学习目标边界被实验清楚识别。后文预算感知实验将专门回到这一张力；下一步

先检验全局增量能否跨时间保持。

6.2 冻结未来窗口上的零样本泛化

Porto 和 Chicago 的三个 BRIDGE 种子在 future Spearman 上均超过各自 Z0。结合空间 holdout，BRIDGE 在两城、三种子、两外部窗口的 12 次配对比较中全部取得正增量，构成本文神经增强稳定性的核心证据。Porto 的 Y/F 区域收益 Spearman 高达 0.9959，因此该结果对应稳定需求时段下的时间外泛化；强分布漂移仍需专门实验。Chicago 的区域收益在 Y 与 F 间变化更大，BRIDGE 的全局增量也更大，但 Top-K 仍存在波动。确认可预测性和时间迁移后，下一步检验 Z0 的信号究竟来自哪里。

6.3 机制消融：Z0 的信号来源

度保持重连保留每个节点的入度和出度，却破坏真实道路邻接；两城四个切分均出现大幅下降，支持“正确道路拓扑对全局区域价值轴具有独立贡献”。仅起点和仅终点均低于双向 Z0，且终点场贡献更强。无向图的全局相关性接近 Z0，但未来 NDCG@5 更低，说明方向信息主要影响头部。保持两侧边际需求的 OD 重耦合几乎不改变结果，因此现有证据支持边际需求传播，不支持原始 OD 配对关系是必要因素。max pooling 几乎复现全局排序，mean pooling 明显较弱；多深度读出在不同切分间更稳健，但不存在对所有指标都最优的单一深度。简言之，全局价值轴依赖真实邻接和双侧需求；下一步检验它能否经受部署自身的冲突约束。

6.4 从单区域排序到严格非重叠部署

直接按 Z0 分数选择 Porto Top-18 时，候选并集只有 2,773 个唯一节点，成员冗余系数为 3.323，并存在共享 116 个节点的候选对，无法由当前索引共同物化。hard-disjoint 贪心最终选满 18 个互不重叠区域，覆盖 9,216 个唯一节点。该变化牺牲部分单区域平均收益，却得到语义明确的可部署集合，说明“预测高价值区域”和“组成高价值区域集合”是两个不同层次的问题。

Porto 中，BRIDGE 相对 Z0 仅多减少约 0.13/0.04 个百分点的当前/未来展开节点，同时 shortcut 增加约 15.5%，因此 Z0 的性能-存储性价比更高。Chicago 中，Z0 在展开节点上优于 BRIDGE 与 Proxy。加入 BRIDGE-B 后，两城全部 Python 在线评测合计 228,000 个查询-索引配对，距离正确率均为 100%。该结果再次表明，全局排序增量需要经过部署评测后才能解释为系统收益。全局顺序与预算头部的张力在真实部署中具体表现为成本，接下来进一步检验工作量能否转

表 2: 空间 holdout 排序结果。MLP 为五种子均值, BRIDGE 为三种子均值。

城市	方法	Spearman	NDCG@18
Porto	midpoint Proxy	0.891756	0.983040
	MLP	0.869552 $\pm$ 0.019732	0.959260 $\pm$ 0.014273
	Z0	0.935603	0.974533
	BRIDGE	0.945902 $\pm$ 0.001699	0.974551 $\pm$ 0.000110
Chicago	midpoint Proxy	0.895597	0.867650
	MLP	0.847990 $\pm$ 0.023984	0.901271 $\pm$ 0.028814
	Z0	0.941135	0.922494
	BRIDGE	0.946787 $\pm$ 0.001144	0.866699 $\pm$ 0.033993

表 3: 冻结未来窗口结果。

城市	方法	Spearman	NDCG@5	NDCG@18
Porto	Z0	0.944656	0.944421	0.933698
	BRIDGE	0.956598 $\pm$ 0.001580	0.893761 $\pm$ 0.005628	0.919343 $\pm$ 0.001397
Chicago	Z0	0.897509	0.659842	0.786935
	BRIDGE	0.925712 $\pm$ 0.000866	0.697910 $\pm$ 0.046648	0.765981 $\pm$ 0.030726

化为墙钟收益。

6.5 同一 C++ 实现下的墙钟性能

C++ 评测包含 800,000 个正式计时配对样本, 距离正确率为 100%, 并精确重放 Python 的区域与 shortcut。Porto 的展开与扫边同时减少, 因而平均耗时和 P95 均下降。Chicago 虽减少约 20% 的展开节点, 但密集边界 shortcut 使扫边增加 18%–28%, 抵消了典型查询的收益; 20 个方法-窗口组合中仍有 14 个 P95 下降。区域物化是否加速因此取决于边界形状与 shortcut 密度, 而不仅取决于区域排序精度。这是把索引成本直接纳入训练目标的第二个物理动机, 下一节转向预算感知训练。

6.6 BRIDGE-B 的预算感知部署

在训练 BRIDGE-B 前, 本文先构造零训练线性后处理 E0, 以检验成本感知是否只需在已有 BRIDGE 分数上减去一个成本项。E0 将预测分数和单区域 shortcut 数分别转换为全候选百分位排名, 并固定使用 $r_i = \text{rank}(s_i) - \lambda \text{rank}(c_i)$, 其中 $\lambda \in \{0.1, 0.3\}$ 。两城三个种子共 12 个固定配置全部执行 $K = 18$ 、Y/F 精确在线门, 未根据结果扩大权重网格。E0 在 Porto 将 shortcut 从 Z0 的 6,712 降至 3,135–4,499, 但六组 Y/F 相对 Z0 均多展开约 28–110 个节点, 呈现明显的成本-收益失衡; Chicago 虽将 shortcut 从 23,378 降至 13,049–15,122, 也只有 seed 43、 $\lambda = 0.3$ 在 Y/F 同时略优于 Z0。12 个配置仅 1 个达到两窗口联合在线门, 暴露出固定线性惩罚对城市、种子和权重的高度敏感。24 个方

法-窗口在线结果的距离正确率均为 100%, 因此问题不在索引正确性, 而在简单事后减法缺乏稳定协调成本与真实部署收益的能力。E0 可以激进削减 shortcut, 却难以作为可靠的多目标部署方案, 也没有复现 BRIDGE-B 在 Porto 的跨种子一致改善。相比之下, BRIDGE-B 将成本、头部收益、区域冲突和完整排序纳入同一学习目标, 实现三个种子完全一致的部署成员和 Y/F 稳定改善。这一对照直接支持联合训练的必要性; E0 更低的 shortcut 仅代表其更偏向存储压缩端点, 不改变其在线收益稳定性明显不足的结论。

S0–S2 以 seed 42 进行短训方法开发。S2 只把式(18)中的 Top- K 收益权重从 0.25 提高到 1.0, 首次 Porto 同时降低 shortcut 与 Y/F 展开节点; 随后 S3 完全冻结该协议, 补充 seeds 43/44, 并对三个种子统一执行全候选推理和精确在线门。结果如下。

Porto 三个种子的 Top-18 成员集合完全相同, 仅集合内部次序发生少量交换; 三种子的 Y/F 展开量标准差均为 0, shortcut 也稳定从 Z0 的 6,712 降至 6,644。这说明 BRIDGE-B 在 Porto 不仅保住了头部, 而且把预算目标稳定转化为真实在线工作量改善。

Chicago seeds 42/43 的成员集合相同, seed 44 部分变化。三个种子的 holdout Spearman 均高于 Z0 的 0.941135, NDCG@5 均高于 0.940545, shortcut 也全部低于 23,378; 但 Y/F 展开量三种子均值仍比 Z0 多 65.947/72.032。相对于 Z0 每查询 2,609.917/2,530.114 个展开节点, 这一差距约为 2.53%/2.85%; Porto 的改善约为 0.84%/0.87%。因此两城真实在线工作量均可视为与 Z0 基本持平, 其中 Porto 小幅更优、Chicago 小幅更高。BRIDGE-B 已在两城稳定学会全局排序、头




图 2: 两城空间留出集 (H/O) 与未来窗口 (F) 的排序性能。BRIDGE 显示三个随机种子的均值与总体标准差。全局 Spearman 稳定提升, 而头部 NDCG 独立变化, 直观展示两类训练目标的差异。

表 4: 正确道路拓扑与度保持随机重连的 Spearman 对照。

城市与窗口	Z0	度保持随机重连	绝对下降
Porto holdout	0.935603	0.556581	0.379022
Porto future	0.944656	0.572467	0.372189
Chicago holdout	0.941169	0.605370	0.335799
Chicago future	0.897844	0.454814	0.443030

部和索引成本控制, 而展开节点变化被控制在不足 3% 的范围。三种子合计 24,000 次 BRIDGE-B 在线配对距离正确率为 100%。该结果把“索引更省”“头部收益更高”和“集合查询展开更少”进一步拆分为三个相关但不等价的训练目标。

6.7 不同查询尺度下的适用性

为避免城市平均值掩盖局部差异, 本文冻结所有选择结果后, 以 Z0 为参照, 将每条查询的展开节点差映射到固定 16×16 米制等边方格。热点只由历史窗口 H 的端点频次定义, 改善、持平和平退化网格全部保留。Porto 中, BRIDGE-B 在 Y/F 的有效网格改善比例分别为 87.8%/90.0%, 且历史头部与非头部的平均展开差均为正, 属于“收益扩展”而不是牺牲头部换覆盖。Chicago 的对应比例为 41.2%/43.3%, 头部和非头部均未稳定超过 Z0; 因此空间覆盖改善不是可跨城市外推的结论。这些地图是已解锁 Y/F 上的机制诊断, 不作为新的时间外确认。

进一步按原图双向 Dijkstra 的逐查询展开量等频分为四组, 每组 500 条查询。表 8 报告 BRIDGE-B 相对原图的结果; 正的减少率表示压缩查询展开更少。

Porto 的高工作量查询每条可少展开约 4,800–5,000 个节点; Chicago 的最低四分位原本只展开约

240–265 个节点, 端点接入和 shortcut 扫描的固定开销无法摊薄, 反而增加工作量, 但最高四分位仍减少约 25%。按 OD 直线跨度分组也得到相同方向: Chicago 最长四分位在 Y/F 分别减少 24.3%/25.0%。这支持一个明确的适用边界: 选择性区域物化更适合出租车、驾车等中长距离或高搜索工作量查询; 步行、骑行等短查询负载可能难以覆盖固定索引接入成本。这里证明的是查询尺度效应, 而不是交通方式本身的因果效应; 城市图结构与出行方式在两组数据中同时变化。同时, 该表比较的是整个压缩框架与原图, 不能据此声称 BRIDGE-B 在 Chicago 长查询上超过 Z0。

7 讨论

7.1 确定性主方法与神经增强的分工

实验支持一个分层结论。Z0 无需标签和训练, 已经获得较强的全局排序与在线工作量收益, 适合作为部署主方法。BRIDGE 在两城、三种子和两个外部窗口组成的 12 次比较中全部提高全局 Spearman, 证明神经网络稳定提取了冻结先验未覆盖的排序信息。这使 BRIDGE 成为具有跨空间、跨时间重复证据的全局排序增强; 实际部署时, 再根据预算目标选择 Z0 或相应的神经增强版本。BRIDGE-B 则进一步承担固定预算




图 3: Z0 的正交机制消融。度保持随机重连在两城当前与未来窗口均显著破坏排序，单侧需求、池化与单深度读出则呈现城市和窗口依赖；完整结果均予展示。

下的头部与成本控制：其三种子结果表明，神经增强不只能优化完整排序，也能在显式约束下形成稳定部署集合。两城在线展开与 Z0 的差异均不足 3%；Porto 可在降低 shortcut 的同时获得小幅工作量改善，Chicago 则可在仅付出小幅展开差异时换取更低 shortcut 与更强头部排序。实际系统可根据存储成本和查询工作量偏好选择二者。

7.2 全局排序与头部决策的目标分离及工程意义

本文的另一项重要发现是，全局排序和头部选择并非同一目标的两种近似度量。Spearman 约束全部候选之间的相对次序，而 NDCG@ K 和最终部署只关注预算截断点附近的少量候选；hard-disjoint 选择还会引入区域重叠和 shortcut 成本。BRIDGE 在 12/12 次比较中提高全局 Spearman，而头部指标随城市和预算独立变化，这一可重复分离实证证明了两类训练目标不可互相替代。该发现把原本容易被混为一谈的“排序更准”和“预算内选得更好”明确拆开，也为后续预算感知损

失和集合级学习提供了直接依据。

从工程角度看，全局排序也不是脱离部署的“平均指标”。真实系统中的 K 会随存储和预处理预算变化，高分区域可能因空间重叠、shortcut 过密或临时不可用而被淘汰，此时系统必须持续从排序后部补充候选。只围绕一个固定 Top- K 优化，容易把资源集中在少数当前热点，并在预算或约束改变后降低不同预算间的决策复用性；高质量的完整排序则为不同预算提供同一条可复用决策轴。结合本文的全图空间均匀候选和历史 OD 传播，这条决策轴能够同时考虑繁忙区域与其余道路区域的实际需求-收益关系，更适合全图资源调度。这里的“顾及全图”指工程覆盖与预算适应性，不预设人口或行政意义上的公平结论。

7.3 预算感知增强的贡献与边界

BRIDGE-B 的意义不在于把几十个展开节点差异夸大为显著加速。更重要的是，它把原先观察到的目标分离转化成可操作的训练设计：soft Spearman 维持完整候选轴，可微 Top- K 直接保护预算截断点，shortcut

表 5: $K = 18$ 严格非重叠部署的在线展开节点结果。负值表示相对原图减少。

城市	方法	Shortcuts	当前展开变化	未来展开变化
Porto	随机	7,986	-4.91%	-4.73%
	历史热点	7,235	-15.84%	-15.90%
	midpoint Proxy	8,307	-17.35%	-17.66%
	Z0	6,712	-17.46%	-17.76%
	BRIDGE (三种子)	7,755	-17.59%	-17.80%
Chicago	随机	26,011	-4.40%	-4.07%
	历史热点	20,093	-17.37%	-17.95%
	midpoint Proxy	21,516	-20.30%	-21.08%
	Z0	23,378	-21.47%	-21.92%
	BRIDGE (三种子)	20,718	-19.62%	-20.28%

表 6: C++20/O3 同实现的 $K = 18$ 性能变化。负值表示降低。

城市	方法	平均耗时		P95 耗时		扫描边	
		当前	未来	当前	未来	当前	未来
Porto	Z0	-6.51%	-7.48%	-4.72%	-6.24%	-6.67%	-6.91%
	BRIDGE	-6.41%	-8.90%	-5.56%	-8.96%	-5.85%	-6.05%
	BRIDGE-B	-6.06%	-7.85%	-4.77%	-6.37%	-7.83%	-8.12%
Chicago	Z0	+3.57%	+0.72%	-3.13%	-3.85%	+26.56%	+27.51%
	BRIDGE	+3.03%	+3.02%	-2.24%	-1.33%	+18.58%	+19.26%
	BRIDGE-B	+4.64%	+3.89%	+0.30%	-0.52%	+23.49%	+24.50%

注: BRIDGE 与 BRIDGE-B 为三种子均值; 表中省略标准差, 完整数值保留在实验产物中。

预算约束物化成本, 冲突项则提前考虑 hard-disjoint 可部署性。三种子中 Porto 的部署成员完全一致, Chicago 的全局、头部与成本方向也一致, 说明这些约束不是偶然命中单个种子。

Chicago 的展开量边界同样提供了明确机制信息。shortcut 数只描述覆盖图边密度的一部分, 单区域收益标签也不等于多个区域同时物化后的联合边际收益; 端点接入、区域组合和搜索次序都会改变最终展开量。因此, BRIDGE-B 当前可被准确表述为“稳定的预算感知排序与成本增强, 在保持 Z0 量级在线工作量的同时降低 shortcut, 并在 Porto 实现小幅真实工作量优势”, 而不把不足 3% 的跨城差异渲染成全面替代或明显退化。这一结果为下一版集合级工作量代理给出直接实验依据。

7.4 工程适用范围

查询尺度分层表明, 当前框架主要适用于存在重复查询、允许离线预处理、要求精确距离且单次原图搜索工作量足以摊薄索引接入成本的静态道路分析任务。候选区域固定为 512 个节点, 区域尺度、标签构造成本和边界 shortcut 密度仍会影响方法的性能-存储权衡。

7.5 略有局限性与后续工作

Porto 出租车与 Chicago 共享单车提供了跨城市、跨出行方式证据, 但尚未覆盖强需求突变、动态边权和更多路网密度。本文通过时间隔离、空间重叠组隔离、冻结多种子评测和逐查询距离校验降低偏差, 但预算感知扩展是在主实验已解锁当前与未来窗口后开发的; 其跨种子稳定性已经确认, 新的时间外结论仍应由后续窗口或未见城市验证。查询方式与城市图结构同时变化, 因此本文只主张查询尺度效应, 不把两城差异解释为交通方式的因果关系。

后续可进一步研究集合级展开/扫边代理、边界 shortcut 稀疏化、动态需求更新和更多城市复现。由于 BRIDGE-B 的开发阶段已经查看当前 Y/F, 下一次方法冻结后应增加新的未来窗口或未见城市, 而不是继续在同一窗口扩大权重网格。对于 Chicago 一类密集边界图, 将联合扫边与端点接入直接纳入选区目标, 可能比继续扩大同一 Top- K 收益权重更有效。

8 结论

围绕“历史需求能否在有限预算下指导精确区域物化”这一主问题, 本文给出了肯定但有边界的答案。无参数传播能够形成强区域价值排序, 神经残差又在 12/12 次跨城市、跨种子和跨窗口配对中一致改善完整




图 4: C++20/O3 同实现下, 选择性物化在两城中的系统收益与成本。负值表示相对原图减少; Chicago 虽减少展开节点, 却因密集 shortcut 增加扫边量, 说明排序收益与墙钟加速并不等价。

排序; 预算感知训练则把头部收益、索引成本与区域冲突纳入同一决策, 在 Porto 得到稳定在线改善, 并把 Chicago 相对强先验的工作量差控制在 3% 内。所有在线查询均保持精确距离, 说明人工智能可以作为现有最短路服务之外的离线资源配置器, 而不必接管查询本身。实验同时证明, 完整排序、预算头部和真实部署收益是不同目标: 前者支持预算变化、冲突淘汰和全图候补, 后两者仍需集合级在线验证。该框架更适合能够摊薄接入成本的中长距离或高工作量查询, 并可通过异步旁路采样、离线统计和周期性物化接入现有工程系统。

A 深层训练稳定性诊断

早期 32 层网络曾出现约 22 个 epoch 不更新, 随后突然变化。逐步诊断发现, FP16 的默认动态缩放导致早期 optimizer step 被跳过; 在 FP32/BF16 下, 梯度元素本身仍有限, 但全局范数的 FP32 平方和发生溢出, 裁剪系数继而接近零。32 层反向 hook 从未层约 10^{-6} 放大到首层约 10^{19} 。式(10)中的严格恒等路径使深

层训练稳定。此后又发现旧 pairwise loss 与 Spearman 方向错位, 最终冻结 soft Spearman 协议。该诊断区分了数值可训练性与任务目标有效性, 但不影响正文围绕区域物化主问题的证据结构。

B 冻结配置摘要

C 空间收益异质性图

声明

数据可用性: 原始数据来自正文引用的公开数据源; 处理后数据、固定切分与标签的公开范围和永久链接将在投稿前完成许可证审计后填写。

代码可用性: 匿名复现仓库及归档链接将在投稿前补充。

生成式人工智能辅助声明: 在本研究和稿件准备过程

表 7: BRIDGE-B 三种子冻结排序与 $K = 18$ 在线结果。 $\Delta Y/\Delta F$ 为相对 Z0 的每查询展开节点差, 负值表示更优。

城市	Seed	Holdout Spearman	NDCG@5	Shortcuts	ΔY	ΔF
Porto	42	0.937893	0.930720	6,644	-75.478	-76.201
	43	0.939052	0.930720	6,644	-75.478	-76.201
	44	0.938122	0.930720	6,644	-75.478	-76.201
Chicago	42	0.942985	0.994012	23,104	+54.250	+62.103
	43	0.942172	0.994012	23,104	+54.250	+62.103
	44	0.942121	0.959441	22,581	+89.340	+91.889


S0-S2: seed 42 development; S3: mean $\pm$ SD over frozen seeds 42-44.

图 5: BRIDGE-B 从 S0 到 S3 的真实部署轨迹。S0-S2 为 seed 42 方法开发; S3 为冻结 seeds 42/43/44 的均值与总体标准差。Porto 获得零方差稳定改善, Chicago 稳定降低 shortcut 并保住头部; 两城与 Z0 的在线展开差均不足 3%。

中, 作者使用 OpenAI Codex 辅助部分研究代码、测试与实验脚本的编写、重构和调试, 以及文章结构与语言表达。相关代码和文本均由作者审阅、测试、核验并按需修改; 实验数据来自真实程序执行, 方法选择、结果解释和科学结论由作者作出。作者对论文全部内容承担责任。利益冲突、基金、作者贡献和致谢列于单独标题页。

参考文献

- Tangpeng Dan, Xiao Pan, Bolong Zheng, and Xiaofeng Meng. FAHL: An efficient labeling index for flow-aware shortest path querying in road networks. In *2025 IEEE 41st International Conference on Data Engineering (ICDE)*, pages 836–849. IEEE, 2025. doi: 10.1109/ICDE65448.2025.00068.
- Daniel Delling, Andrew V. Goldberg, Thomas Pajor, and Renato F. Werneck. Customizable route planning in road networks. *Transportation Science*, 51(2):566–591, 2017. doi: 10.1287/trsc.2014.0579.
- Edsger W. Dijkstra. A note on two problems in connexion with graphs. *Numerische Mathematik*, 1:269–271, 1959. doi: 10.1007/BF01386390.
- Divvy. Divvy system data: Historical trip data. <https://divvybikes.com/system-data>, 2022. Accessed 2026-07-31.
- Alexandros Efentakis, Dieter Pfoser, and Yannis Vassiliou. SALT: A unified framework for all shortest-path query variants on road networks, 2014.
- Fabrizio Frasca, Emanuele Rossi, Davide Eynard, Ben Chamberlain, Michael M. Bronstein, and Federico Monti. SIGN: Scalable inception graph neural networks, 2020.
- Rolf Jagerman, Xuanhui Wang, Honglei Zhuang, Zhen Qin, Michael Bendersky, and Marc Najork. Rax: Composable learning-to-rank using JAX. In *Proceedings of the 28th*

表 8: BRIDGE-B 对查询工作量尺度的适用性。Q1/Q4 分别为原图展开量最低/最高四分位。

城市	窗口	Q1 原图展开	Q1 减少率	Q4 原图展开	Q4 减少率	Q4 少展开节点
Porto	Y	661	+3.98%	32,015	+15.74%	5,039
	F	727	+9.18%	30,464	+15.90%	4,843
Chicago	Y	265	-97.11%	9,663	+24.92%	2,408
	F	238	-111.08%	9,212	+25.72%	2,370

表 9: 正式实验的关键冻结配置。

项目	固定值
时间窗口	$H = [0, 0.35)$, $Y = [0.35, 0.70)$, $F = [0.70, 1.00)$
候选	每城 1,200 个, 每候选 512 节点, 候选种子 42
空间隔离	Jaccard 阈值 0.50 的重叠连通组, 840/180/180
标签查询	每城、每窗口、每候选 2,000 条, 抽样种子 42, 端点缓存关闭
Z0	正反向 lazy mean, 深度 1/2/4/8/16/32, 区域 mean+max
BRIDGE	32 层双塔, hidden dim 32, 残差尺度 0.01, 418,183 参数
优化	CUDA FP32, 学习率 5×10^{-3} , weight decay 0, 40 epoch, 无 scheduler
模型选择	seeds 42/43/44, validation Spearman, $\alpha \in \{0, 0.125, 0.25, 0.5, 1\}$
BRIDGE-B	同一双塔与冻结 Z0, 12 epoch, Top-K/预算/冲突权重 1.0/1.0/0.10
BRIDGE-B 选择	validation Top-K 收益最大, shortcut 不高于 Z0, Spearman 容差 0.005
部署	hard-disjoint, $K = 5/10/18$; 主系统表报告 $K = 18$
C++ 计时	C++20/O3, 固定单核, 2 轮预热, 10 轮正式重复, 每组 2,000 查询

ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pages 3051–3060. ACM, 2022. doi: 10.1145/3534678.3539065.

Guohao Li, Chenxin Xiong, Ali Thabet, and Bernard Ghanem. DeeperGCN: All you need to train deeper GCNs, 2020a.

Xiaohua Li, Bin Wang, Tao Qiu, Ge Yu, and Ning Wang. Constructing effective caches of shortest path queries on road networks. *IEEE Access*, 8:193777–193789, 2020b. doi: 10.1109/ACCESS.2020.3024664.

Yaguang Li, Rose Yu, Cyrus Shahabi, and Yan Liu. Diffusion convolutional recurrent neural network: Data-driven traffic forecasting. In *International Conference on Learning Representations (ICLR)*, 2018. URL <https://arxiv.org/abs/1707.01926>.

Luis Moreira-Matias, Michel Ferreira, Joao Mendes-Moreira, et al. Taxi service trajectory—prediction challenge, ECML PKDD 2015, 2013.

OpenStreetMap contributors. Openstreetmap. <https://www.openstreetmap.org/copyright>, 2026. Open Database License; accessed 2026-07-31.

Jeppe Rishede Thomsen, Man Lung Yiu, and Christian S. Jensen. Effective caching of shortest paths for location-based services. In *Proceedings of the 2012 ACM SIGMOD*

International Conference on Management of Data, pages 313–324. ACM, 2012. doi: 10.1145/2213836.2213872.

Hugo Touvron, Matthieu Cord, Alexandre Sablayrolles, Gabriel Synnaeve, and Hervé Jégou. Going deeper with image transformers. In *Proceedings of the IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 32–42, 2021.

Jingyi Wan, Yongyong Gao, Yong Ma, Kai Huang, Xiaofang Zhou, Christian S. Jensen, and Bolong Zheng. Workload-aware shortest path distance querying in road networks. In *2022 IEEE 38th International Conference on Data Engineering (ICDE)*, pages 2372–2384. IEEE, 2022. doi: 10.1109/ICDE53745.2022.00223.

Keyulu Xu, Chengtao Li, Yonglong Tian, Tomohiro Sonobe, Ken ichi Kawarabayashi, and Stefanie Jegelka. Representation learning on graphs with jumping knowledge networks. In *Proceedings of the 35th International Conference on Machine Learning*, volume 80 of *Proceedings of Machine Learning Research*, pages 5453–5462. PMLR, 2018.

Zhaocheng Zhu, Zuobai Zhang, Louis-Pascal Xhonneux, and Jian Tang. Neural bellman-ford networks: A general graph neural network framework for link prediction. In *Advances in Neural Information Processing Systems*, volume 34, 2021. URL

<https://proceedings.neurips.cc/paper/2021/hash/f6a673f09493afcd8b129a0bcf1cd5bc-Abstract.html>.




图 6: Porto 中 BRIDGE 与 BRIDGE-B 相对 Z0 的 Y/F 逐查询展开节点空间差。蓝色表示神经方法更少展开；BRIDGE-B 的正收益覆盖在两个窗口均较广。




图 7: Chicago 中 BRIDGE 与 BRIDGE-B 相对 Z0 的 Y/F 逐查询展开节点空间差。正负网格并存，说明局部改善没有转化为城市平均优势。